

Peyk

Model maliyeti ve açık ağırlıklı model alternatifleri

Teknik değerlendirme raporu

Kapsam. Peyk'in kullanıcı başına model maliyetinin ölçülmesi, Claude Haiku 4.5 yerine açık ağırlıklı (open-weight) modellere geçiş senaryolarının değerlendirilmesi ve maliyet-kalite dengesinin nicel olarak ortaya konması.

Temel bulgu. Açık modele geçiş, maliyet sıralamasında yanlış adımdır. Mevcut kodda yapılacak ve hiçbir kalite riski taşımayan üç değişiklik aylık \$12,06 kazandırır; triage'ı açık bir modele taşımak bunun üzerine yalnızca \$3,55 ekler ve ürünün tek teknik iddiasını riske atar.

İçindekiler

1	Yönetici özeti	2
2	Yöntem ve kaynak güvenilirliği	2
2.1	Ölçülen veriler (yüksek güven)	2
2.2	Varsayılan veriler (düşük güven, doğrulanmalı)	2
3	Ölçülen token profili	3
3.1	Görev bazında maliyet payı	3
4	Maliyet nerede yoğunlaşıyor	3
4.1	Önbelleklemede sessiz bir tuzak	4
5	Hangi iş yükü takas edilebilir?	4
6	Açık ağırlıklı model manzarası	4
6.1	Bedrock içinde kalan seçenekler	5
6.2	Bedrock dışı seçenekler ve gizli maliyeti	5
6.3	Fiyat bantları	5
7	Senaryo matrisi	5
8	Triage fiyat duyarlılığı	6
9	Kendi altyapında barındırma (self-hosting)	6
10	Kalite riski: asimetrik maliyet	7
11	Karar protokolü	7
11.1	Önce: değerlendirme seti büyütülmeli	7
11.2	Sonra: gölge modu	8
11.3	Kabul kriterleri	8
12	Sonuç ve yol haritası	8
A	Modeli yeniden çalıştırma	9
B	Token sayımlarının kaynağı	9

1. Yönetici özeti

Peyk'in bugünkü kullanıcı başına model maliyeti, orta yoğunlukta bir kullanıcı için (günde 50 mail, 8 sohbet turu) **aylık \$19,30**'dur. Bu rakam \$25'lik bir abonelik fiyatında %23 brüt marj bırakır ki, Composio ve altyapı eklendiğinde sıfıra iner.

Sorunun kaynağı model *seçimi* değil, model *kullanımıdır*. Maliyetin %73'ü sohbet akışından gelir ve bu akış, her çağrıda 12.401 token'lık bir girdiyi önbellesiz olarak yeniden göndermektedir.

Bu raporun ana sonucu: Takas edilmesi *kolay* olan iş yükü (triage) ucuz olandır; pahalı olan iş yükü (sohbet) ise takas edilmesi *riskli* olandır. Açık model geçişi, optimizasyonlardan önce yapılırsa üçte bir kadar kazanç için ürünün güvenilirliği riske atılmış olur.

Önerilen sıra:

1. **Ölçüm altyapısı** (1 hafta). Her model çağrısının `usage` alanı veritabanına yazılmadan hiçbir karar veriyeye dayanmıyor.
2. **Risksiz optimizasyonlar** (1–2 hafta). Prompt caching, bağlam küçültme, araç setinin bölünmesi, Sonnet 5'e geçiş. \$19,30 → \$7,24.
3. **Değerlendirme setinin büyütülmesi** (2–3 hafta). Mevcut 60 mail'lik eval, model karşılaştırması için istatistiksel olarak yetersizdir.
4. **Gölge modu ile aday ölçümü** (3–4 hafta). Ancak bundan sonra açık model kararı verilebilir; beklenen ek kazanç \$3,55.

2. Yöntem ve kaynak güvenilirliği

Bu raporun iki tür girdisi vardır ve ikisi çok farklı güvenilirlik taşır.

2.1 Ölçülen veriler (yüksek güven)

Token sayıları 15 Eylül 2026 tarihinde `akware/peyk` deposundan doğrudan çıkarılmıştır. Kaynaklar Ek B'de dosya ve satır numarasıyla listelenmiştir. Sayımlar karakter uzunluğunun 4'e bölünmesiyle yapılmıştır; gerçek tokenizer çıktısına göre $\pm\%30$ sapma payı vardır.

2.2 Varsayılan veriler (düşük güven, doğrulanmalı)

Uyarı. Bu raporun hazırlandığı ortamın ağ politikası fiyat kaynaklarının tamamını engellemiştir: `aws.amazon.com/bedrock/pricing`, `docs.aws.amazon.com`, `openrouter.ai`, `artificialanalysis.ai`, `huggingface.co` ve `together.ai` çağrıları 403 ile reddedilmiştir. Hiçbir fiyat canlı kaynaktan doğrulanamamıştır.

Bu kısıt nedeniyle rapor iki savunma mekanizması kullanır:

- **Anthropic fiyatları** liste fiyatlarıdır (Haiku 4.5 \$1/\$5, Sonnet 4.6 \$3/\$15, Sonnet 5 \$2/\$10 — milyon token başına giriş/çıkış). Bedrock ayrı fiyatlandırılan bir iş ortağı platformudur; Claude modellerinde tarihsel olarak liste fiyatıyla örtüşmüştür ancak **bu doğrulanmalıdır**.
- **Açık model fiyatları tedarikçi iddiası olarak değil, fiyat bandı olarak** modellenmiştir (Bant A–D, \$0,05–\$0,70). Böylece sonuçlar belirli bir satıcının güncel fiyatına bağlı kalmaz. Hangi modelin hangi banda düştüğü Bölüm 6'da ayrıca tartışılmıştır ve doğrulanması gereken tek şey budur.

Tüm hesaplar `docs/cost/model.py` dosyasındadır. Fiyatlar tek bir sözlükte parametredir; güncellenip çalıştırıldığında bu rapordaki her tablo yeniden üretilir.

3. Ölçülen token profili

Çağrı	Girdi	Çıktı	Sıklık
Triage (Haiku 4.5)	1.740	150	her dış olay
Ack / refleks (Haiku 4.5)	1.330	60	her sohbet turu
Sohbet (Sonnet 4.6)	12.401	250	her sohbet turu $\times 1,4$

Tablo 1: Çağrı başına token profili. Ack ve sohbet her kullanıcı mesajında birlikte çalışır.

Buradan çıkan birim maliyetler: **bir mail triage’ı \$0,0025, bir sohbet turu \$0,0590.** Depodaki `docs/DEPLOY.md` dosyası triage için “\$0,001 per mail” demektedir; gerçek rakam bunun 2,5 katıdır. Fark, mailin kendisinden değil, her çağrıda yeniden gönderilen 1.140 token’lık sistem promptundan kaynaklanır.

3.1 Görev bazında maliyet payı

Görev	\$/ay	Pay
Triage	3,73	19,4%
Sohbet	14,15	73,3%
Sabah brief	1,42	7,3%

Tablo 2: Orta profil (50 mail, 8 sohbet/gün), bugünkü yapılandırma.

Bu tablo raporun geri kalanını belirler: **trriage toplam maliyetin yalnızca %19,4’üdür.** Triage’ı tamamen bedava bir modele taşımak bile, en iyi ihtimalle aylık \$3,73 kazandırır.

4. Maliyet nerede yoğunlaşıyor

Bir sohbet turunun 12.401 token’lık girdisinin dağılımı:

Bileşen	Token	Pay
<code>recent_observations</code> (limit 50)	5.000	40,3%
23 adet @tool şeması	3.350	27,0%
<code>CHAT_SYSTEM_PROMPT</code>	3.126	25,2%
Geçmiş 10 tur	625	5,0%
Hafıza + kullanıcı + iskele	300	2,4%

Tablo 3: Sohbet girdisinin bileşenleri (`workers/chat.py`).

Üç yapısal sorun görünüyor:

- Bağlam peşin yükleniyor.** `RECENT_LIMIT` = 50, 48 saatlik 50 gözlemi her sohbete önden koyuyor — girdinin %40’ı. Oysa ajanda zaten `need_more` aracı var; veriyi isteyebiliyor. Bu, tek satırlık bir değişiklik ile düzelir ve önbelleklemeye hiç bağlı değildir.
- 23 araç şeması her çağrıda gidiyor.** Takvimle ilgili altı araç (`find_events`, `find_free_time`, `check_time`, `create_event`, `update_event`, `cancel_event`) yalnızca mesajda bir zaman geçtiğinde gereklidir.

3. **Hiçbir yerde prompt caching yok.** Sistem promptu ve araç şemaları birlikte 6.476 token'lık, çağrıdan çağrıya *bayt bayt aynı* bir önek oluşturuyor.

4.1 Önbelleklemede sessiz bir tuzak

Prompt caching'in modele göre değişen bir minimum önek uzunluğu vardır; bu eşğin altında önbellek *sessizce* çalışmaz — hata verilmez, yalnızca `cache_creation_input_tokens` sıfır döner.

Çağrı	Model	Önek	Minimum / sonuç
Sohbet	Sonnet 4.6	6.476 tok	1.024 — çalışır
Triage	Haiku 4.5	1.340 tok	4.096 — sessizce çalışmaz

Tablo 4: Haiku 4.5'in minimum önbelleklenebilir önek uzunluğu 4.096 token'dır.

Sonuç: sohbet önbelleklenebilir, **trriage önbelleklenemez**. Bu, triage'ın birim maliyetini \$0,0025'te sabitler ve açık model arayışının asıl gerekçesini oluşturur.

İlginç bir ara sonuç: triage'ı önbellekli Sonnet 5 ile çalıştırmak \$0,0026'ya mal olur — yani *aynı paraya belirgin biçimde daha güçlü bir model*. Ancak önbelleğin 5 dakikalık yaşam süresi, seyrek gelen maillerde önbelleğin çoğu zaman soğuk olması anlamına gelir; bu durumda yazma cezası (1,25×) devreye girer ve avantaj kaybolur. Sohbet turları kümелendiği için orada aynı sorun yoktur.

5. Hangi iş yükü takas edilebilir?

Her model çağrısının farklı bir gereksinim profili vardır. Takas edilebilirlik, fiyattan önce bu profile belirlenir.

Görev	Yapısal çıktı	Araç çağrısı	Çok dilli	Bağlam	Takas edilebilirlik
Triage	evet	hayır	evet	1,7K	Yüksek
Ack / refleks	evet	hayır	evet	1,3K	Çok yüksek
Learn	evet	hayır	evet	~8K	Yüksek (seyrek)
Sohbet	hayır	23 araç	evet	12,4K	Düşük
Gömme (Titan v2)	—	—	—	—	Zaten ucuz

Tablo 5: İş yükü profilleri. Sohbet dışındaki her şey tek atışlık yapısal çıktıdır.

Triage ve ack tek atışlık sınıflandırma görevleridir: sabit şema, kısa çıktı, araç yok. Açık ağırlıklı küçük modellerin en güçlü olduğu alan tam da budur.

Sohbet ise tersidir. 23 aracın arasından doğru olanı seçmek, çok turlu araç çağrısı zincirini bozmadan yürütmek ve bunu kullanıcının dilinde yapmak, küçük açık modellerin sistematik olarak zorlandığı bir iştir. Üstelik burada bir hata sessiz değildir: yanlış araç çağrısı yanlış bir taslak maile veya yanlış bir takvim değişikliğine dönüşür. Onay akışı (`approval.py`) bunu büyük ölçüde yakalar, ama kullanıcı deneyimi bozulur.

Maliyetin %73'ü sohbette, takas kolaylığının tamamı triagededir. Bu raporun merkezi gerilimi budur: **ucuzlatması kolay olan yer az para tutuyor**.

6. Açık ağırlıklı model manzarası

6.1 Bedrock içinde kalan seçenekler

Bedrock, Claude dışında birden fazla açık ağırlıklı model ailesi barındırır: Meta Llama (3.x ve 4 serisi), Mistral, DeepSeek, Qwen ve gpt-oss aileleri; ayrıca açık ağırlıklı olmayan ama çok ucuz olan Amazon Nova serisi. Bunların Peyk açısından belirleyici avantajı fiyat değil, **tedarikçi değişmemesidir**: aynı IAM anahtarı, aynı bölge, aynı veri işleme sözleşmesi, GDPR alt işleyici listesinde yeni bir satır yok.

6.2 Bedrock dışı seçenekler ve gizli maliyeti

Groq, Together, Fireworks, DeepInfra ve OpenRouter gibi sağlayıcılar aynı açık modelleri genellikle daha ucuza sunar. Ancak Peyk için bu **yalnızca bir fiyat kararı değildir**:

- Triage girdisi kullanıcının *mail gövdesini* içerir (`mappings.py`, `message_text` alanı, 1.200 karakteri kapsar). Yeni bir sağlayıcı, kullanıcının mail içeriğine erişen yeni bir alt işleyicidir.
- Bu, GDPR alt işleyici listesini, kullanıcıya açıklanan gizlilik politikasını ve Google'ın kısıtlı kapsam (restricted scope) değerlendirmesinde beyan edilen veri akışını doğrudan etkiler.
- Aylık \$3,55'lik bir tasarruf için yeni bir DPA müzakeresi, yeni bir güvenlik değerlendirmesi ve gizlilik politikası revizyonu gerekir.

Öneri: Açık model denemeleri Bedrock içinde kalsın. Fiyat avantajının bir kısmı kaybedilir, ancak hukuki ve operasyonel maliyet sıfırdır. Bedrock dışına çıkmak ancak kullanıcı sayısı bu ek yükü haklı çıkardığında — kabaca birkaç bin kullanıcıda — gündeme gelmelidir.

6.3 Fiyat bantları

Belirli tedarikçi fiyatları doğrulanamadığı için modelleme dört bant üzerinden yapılmıştır. Her bandın karşılığı olarak verilen model sınıfları **örnektir, doğrulanmalıdır**.

Bant	Giriş/Çıkış (\$/MTok)	Tipik model sınıfı	Triage için
A	0,05 / 0,20	Nova Micro sınıfı	Kalite riski yüksek
B	0,15 / 0,30	3B–20B açık modeller	Aday
C	0,35 / 0,60	7–8B açık modeller	En dengeli aday
D	0,70 / 0,90	70B açık modeller	Güvenli ama az kazanç
—	1,00 / 5,00	Claude Haiku 4.5 (mevcut)	Referans

Tablo 6: Fiyat bantları. Model sınıfı eşlemeleri doğrulanmayı bekleyen varsayımlardır.

7. Senaryo matrisi

Aşağıdaki tablo kümülatiftir: her satır bir öncekinin üzerine ekler.

Okunması gereken üç eşik:

S0 → S4: \$19,30 → \$7,24. Tamamı mevcut kodda yapılacak değişikliklerdir. Model değişmez, kalite riski yoktur, tek fark Sonnet 4.6 yerine hem daha yeni hem daha ucuz olan Sonnet 5'tir. **Kazanç: \$12,06.**

S4 → S6: \$7,24 → \$3,69. Triage'ın açık modele taşınması. **Kazanç: \$3,55,** ve bu kazanç için ürünün tek teknik iddiası ölçüm altına alınmak zorundadır.

Senaryo		Hafif	Orta	Yoğun
		\$/kullanıcı/ay		
S0	Bugünkü hali	8,22	19,30	45,76
S1	Prompt caching açık	5,43	12,84	30,48
S2	S1 + gözlem 50 → 15	3,75	8,96	21,31
S3	S2 + araç seti bölünmüş	3,67	8,78	20,88
S4	S3 + Sonnet 5	3,01	7,24	17,25
S5	S4 + triage Bant C (\$0,35)	1,68	3,92	9,28
S6	S4 + triage Bant B (\$0,15)	1,59	3,69	8,73
S7	S6 + ack de açık model	1,43	3,32	7,85
S8	S7 + sohbet de Bant D (riskli)	0,46	1,08	2,56

Tablo 7: Kümülatif senaryo matrisi. Hafif = 20 mail + 3 sohbet/gün; Orta = 50 + 8; Yoğun = 120 + 20.

S7 → S8: \$3,32 → \$1,08. Sohbetin de açık modele taşınması. Mutlak kazanç büyüktür (\$2,24) çünkü maliyetin %73’ü oradadır — ama 23 araçlı çok turlu akışta bu, ürünün davranışını baştan doğrulamayı gerektirir. Bu rapor bunu önermez; yalnızca üst sınırı göstermek için tabloda tutulmuştur.

8. Triage fiyat duyarlılığı

Model bandı	\$/MTok	Birim	\$/ay	Tasarruf
Claude Haiku 4.5	1,00 / 5,00	0,00249	3,73	0,00
Bant D: ~\$0,70	0,70 / 0,90	0,00135	2,03	1,71
Bant C: ~\$0,35	0,35 / 0,60	0,00070	1,05	2,69
Bant B: ~\$0,15	0,15 / 0,30	0,00031	0,46	3,28
Bant A: ~\$0,05	0,05 / 0,20	0,00012	0,18	3,56

Tablo 8: Orta profil (50 mail/gün). “Tasarruf” Haiku 4.5’e göre.

Bu tablonun en önemli özelliği **azalan getiridir**. Bant D’den Bant A’ya inmek — yani 14 kat daha ucuz bir modele geçmek — yalnızca \$1,85 ek kazandırır. Maliyetin büyük kısmı zaten sabit sistem promptundadır ve o token’lar hangi modelde olursa olsun gönderilir.

“En ucuz modeli bulma” yarışının anlamı yoktur. Bant C’nin (\$0,35) altına inmenin getirisi \$1,05/ay’dır; buna karşılık model küçüldükçe kalite riski hızla artar. **Aday aralığı Bant C–D’dir.**

9. Kendi altyapında barındırma (self-hosting)

Açık ağırlıklı modelin asıl cazibesi marjinal maliyetin sıfıra yaklaşmasıdır. Ancak sabit maliyet GPU kirasıdır ve başabaş noktası şaşırtıcı biçimde yüksektir.

Yani **yaklaşık 190 aktif kullanıcının altında kendi GPU’nu çalıştırmak doğrudan zarardır** — ve bu hesap yalnızca GPU kirasıdır. Dahil olmayanlar: model sunucusunun (vLLM vb.) işletimi, ölçekleme, yedeklilik, gece nöbeti, model güncellemeleri ve GPU kotası temini.

Ayrıca Peyk’in mevcut mimarisi tek Fly.io makinesine kilitlidir (`fly.toml`, `auto_stop_machines = off`) çünkü Telegram `getUpdates` ve Compositio websocket tek tüketicidir. Kendi model sunucusunu eklemek, henüz yatay ölçeklenemeyen bir sisteme ikinci bir durum bilgili bileşen eklemek anlamına gelir.

Örnek tipi	\$/sa	\$/ay	Sığan model	Başabaş	Kullanıcı
g5.xlarge (A10G 24GB)	1,006	724	7-8B, 4-bit	290,892	194
g6.2xlarge (L4 24GB)	0,978	704	7-8B	282,795	189
g5.12xlarge (4xA10G)	5,672	4.084	70B, 4-bit	1,640,096	1.093

Tablo 9: Başabaş, Haiku 4.5 ile triage maliyetine göre. On-demand fiyatlar varsayımdır.

Self-hosting bu aşamada gündem dışıdır. 200+ ödeyen kullanıcıya ulaşıldığında, ve ancak Bölüm 2'deki webhook geçişi tamamlandıktan sonra yeniden değerlendirilmelidir.

10. Kalite riski: asimetrik maliyet

Ucuz model kararı, tasarrufu kalite riskine karşı tartmadan verilemez. Peyk'te bu denge özellikle asimetriktir çünkü ürünün tüm vaadi “doğru olanı geçiriyorum” iddiasıdır.

İki hata türü eşit değildir:

- **Yanlış pozitif** (önemsizi acil sanmak): kullanıcı bir gereksiz bildirim alır, noise basar, bütçe slotu geri verilir (`budget_repo.py`). Maliyeti düşüktür.
- **Yanlış negatif** (gerçek acili kaçırmak): kullanıcı müşterisini, kirasını veya çocuğunun okulundan gelen çağrıyı kaçırmak. Bu tek olay, ürüne olan güveni bitirir.

Aşağıdaki tablo, bir tasarrufun hangi ek kaçırma oranında sıfırlandığını gösterir. Varsayımlar: abonelik \$25/ay, ortalama ömür 12 ay (LTV \$300), kaçırılan bir acil olayın ayrılmaya yol açma olasılığı %50.

Model bandı	Tasarruf \$/ay	Başabaş ek kaçırma
Bant D: ~\$0,70	1,71	1,14%
Bant C: ~\$0,35	2,69	1,79%
Bant B: ~\$0,15	3,28	2,18%
Bant A: ~\$0,05	3,56	2,37%

Tablo 10: “Başabaş ek kaçırma”, 100 kullanıcı-ayında kaç ek kaçırılmış acilin tasarrufu sıfırladığını gösterir.

Okuması şudur: Bant B'ye geçmek, **100 kullanıcı-ayında 2,2 ek kaçırılmış acile mal olursa** tasarruf tamamen silinir. Bu, çok dar bir hata bütçesidir — ve tam olarak ölçülmesi gereken şeydir.

11. Karar protokolü

Peyk'in bu kararı ampirik olarak verebilecek altyapısı büyük ölçüde hazırdır. `tests/phase1/test_triage_eval.py` 60 etiketli mail üzerinde çalışır; mevcut ölçüm %98 within-1 doğruluk ve 6/6 urgency-5 recall'dur.

11.1 Önce: değerlendirme seti büyütülmeli

60 mail, model *karşılaştırması* için yetersizdir. Kritik metrik olan urgency-5 recall yalnızca 6 örneğe dayanmaktadır; bir modelin 6/6, diğerinin 5/6 alması istatistiksel olarak anlamlı bir fark değildir. Bölüm 10'daki hata bütçesini ölçebilmek için **en az 300 etiketli mail ve bunların içinde en az 30 urgency-5 örneği** gerekir.

Bu setin kaynağı hazırdır: `sent_notification.user_feedback` alanında biriken `useful/noise` geri bildirimleri ve `gate`'in sustuğu olaylar. Ayrıca bu veri zamanla rakiplerin sahip olmadığı bir varlığa dönüşür — küçük bir modelin bu veriyle ince ayarlanması (*fine-tuning*), uzun vadede hem maliyet hem savunulabilirlik avantajıdır.

11.2 Sonra: gölge modu

Aday modeller üretimde şu şekilde risksiz ölçülebilir:

1. Her gerçek triage çağrısı *ayrıca* aday modele de gönderilir.
2. Kullanıcıya **yalnızca** Haiku'nun sonucu gider; aday modelin çıktısı sadece loglanır.
3. İki model arasındaki farklar, özellikle Haiku'nun 4–5 verdiği ama adayın 1–3 verdiği olaylar, elle incelenir.

Gölge modunun maliyeti aday modelin fiyatı kadardır (Bant C için aylık \$1,05) ve kullanıcı için sıfır risk taşır. İki hafta çalıştırmak, bu raporun tüm varsayımlarını gerçek veriyle değiştirir.

11.3 Kabul kriterleri

Metrik	Eşik	Gerekçe
Urgency-5 recall	%100	Kaçırılan acil ürünü bitirir
Within-1 doğruluk	$\geq$ %95	Mevcut: %98
Yapısal çıktı hata oranı	$<$ %0,5	Şema uyumsuzluğu = düşen olay
Türkçe/Almanca özet kalitesi	elle kontrol	Çok dilli özet küçük modellerde zayıflar
p95 gecikme	$<$ 3 sn	Gate zaten dakikalarca bekliyor, esnek

Tablo 11: Bir aday modelin üretime alınabilmesi için karşılaması gereken eşikler.

12. Sonuç ve yol haritası

Faz	İş	Süre	Sonuç
0	usage muhasebesi (<code>model_call</code> tablosu)	1 hafta	Varsayım $\rightarrow$ veri
1	Caching + bağlam + araç bölme + Sonnet 5	1–2 hafta	\$19,30 $\rightarrow$ \$7,24
2	Eval seti 60 $\rightarrow$ 300+ mail	2–3 hafta	Ölçülebilir karar
3	Gölge modu, Bant C–D adayları	3–4 hafta	Kanıt
4	Karar	—	Olası \$7,24 $\rightarrow$ \$3,69

Tablo 12: Önerilen sıralama.

Faz 1 ile Faz 4'ün karşılaştırması bu raporun özeti: birincisi \$12,06 kazandırır ve hiçbir şeyi riske atmaz; ikincisi \$3,55 kazandırır ve ürünün tek teknik iddiasını ölçüm altına almayı zorunlu kılar. İkisi de yapılmalıdır — ama bu sırayla.

\$25'lik fiyat noktasında brüt marjın seyri:

Yoğun kullanıcı satırı ayrıca dikkat ister: bugün ürüne en çok değer veren kullanıcı en çok para kaybettiren kullanıcıdır. Faz 1 bunu düzeltir, ancak uzun vadede bir adil kullanım sınırı gerekecektir. Peyk'in ürün anlatısı buna elverişlidir — knock bütçesinin yanına bir sohbet bütçesi koymak, ürünün hikâyesiyle çelişmez.

Aşama	Hafif	Orta	Yoğun
Bugün (S0)	%67	%23	−%83
Faz 1 sonrası (S4)	%88	%71	%31
Faz 4 sonrası (S6)	%94	%85	%65

Tablo 13: Brüt marj, \$25/ay abonelik. Composio ve altyapı hariç.

A. Modeli yeniden çalıştırma

```
cd docs/cost
python3 model.py           # okunabilir tablolar
python3 model.py --latex   # LaTeX tablo gövdeleri
pdflatex report.tex       # (iki kez)
```

Fiyatlar `model.py` içindeki `PRICES` sözlüğündedir. Bedrock’un gerçek fiyatları doğrulandığında yalnızca o sözlük güncellenir; bu rapordaki her tablo yeniden üretilir. Aynı şekilde `PROFILES` (kullanım yoğunluğu) ve `CHURN_GIVEN_MISS / LTV` (risk varsayımları) da parametredir.

B. Token sayımlarının kaynağı

Değer	Kaynak	Ölçüm
Triage sistem promptu	<code>agent/triage_agent.py</code>	4.151 karakter
Sohbet sistem promptu	<code>agent/chat_agent.py</code>	12.504 karakter
Ack sistem promptu	<code>agent/chat_agent.py</code>	3.121 karakter
23 araç şeması	<code>agent/chat_agent.py</code>	10.358 karakter
Gözlem limiti	<code>workers/chat.py</code>	<code>RECENT_LIMIT = 50</code>
Geçmiş tur sayısı	<code>workers/chat.py</code>	<code>HISTORY_TURNS = 10</code>
Bağlam penceresi	<code>workers/chat.py</code>	<code>RECENT_HOURS = 48</code>
Mail gövdesi kırpma	<code>agent/triage_agent.py</code>	<code>max_text = 1200</code>
Tur sayısı	<code>workers/chat.py</code>	<code>MAX_ROUNDS = 2, MAX_DOC_ROUNDS = 4</code>

Tablo 14: Ölçümlerin depo içindeki kaynakları (15 Eylül 2026).

*Bu rapordaki fiyat varsayımları canlı kaynaktan doğrulanmamıştır (bkz. Bölüm 2).
Herhangi bir tedarikçi kararından önce güncel fiyatlar teyit edilmelidir.*